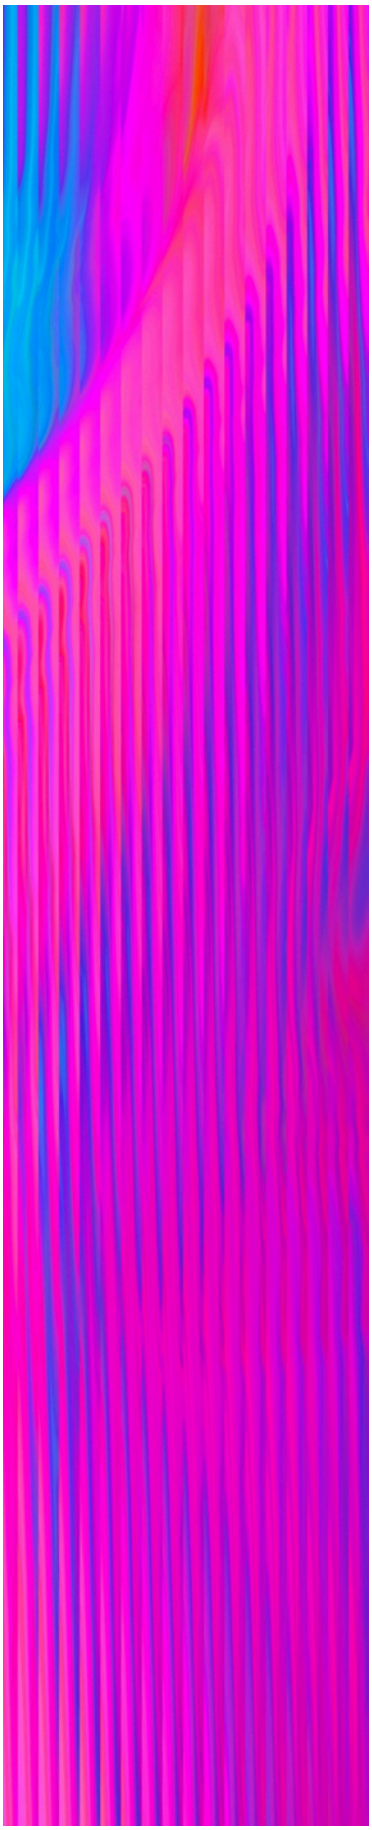

INFORME TÉCNICO

- UNIVERSIDAD DE LOS ANDES
- vISUALIZACION & STORYTELLING

Introducción

Este documento presenta el proceso de preparación y transformación de datos realizado a partir de la encuesta salarial publicada por *Ask a Manager*. El ejercicio simula el trabajo de un equipo de analítica donde, además de generar resultados, es fundamental asegurar que los procedimientos sean claros, trazables y replicables.

Desde una mirada de storytelling para audiencias técnicas, el valor del análisis no está solo en el dashboard final, sino en la capacidad de explicar cómo se limpiaron los datos, qué decisiones se tomaron y cómo se construyeron las nuevas variables. Esta documentación facilita la continuidad del trabajo, la auditoría del proceso y la transferencia de conocimiento.

El informe se organiza en tres partes: descripción de las variables originales, trazabilidad hacia el dataset modelado y el procedimiento para actualizar y ejecutar nuevamente el proceso.

Variables en base de datos original

A continuación, se muestran las variables contenidas en el dataset original, cada una con su descripción y tipo de variable.

Nombre de Variable	Tipo de Variable	Descripción
Timestamp	Fecha / hora	Fecha y hora en la que la persona respondió la encuesta.
How old are you?	Texto categórico	Rango de edad del encuestado.
What industry do you work in?	Texto	Industria o sector económico donde trabaja.
Job title	Texto	Nombre del cargo o puesto.
If your job title needs additional context, please clarify here:	Texto	Campo abierto para detallar funciones o nivel del cargo.
What is your annual salary? (You'll indicate the currency in a later question. If you are part-time or hourly, please enter an annualized equivalent -- what you would earn if you worked the job 40 hours a week, 52 weeks a year.)	Numérico (con posibles errores)	Salario anual reportado antes de impuestos, en la moneda indicada posteriormente. Puede contener abreviaciones o formatos inconsistentes.
How much additional monetary compensation do you get, if any (for example, bonuses or overtime in an average year)? Please only include monetary compensation here, not the value of benefits.	Numérico (con posibles errores)	Ingresos adicionales como bonos o pagos extra recibidos en un año promedio.
Please indicate the currency	Texto categórico	Moneda en la que se reportan salario y compensaciones.
If "Other," please indicate the currency here:	Texto	Especificación de la moneda cuando no aparece en la lista principal.
If your income needs additional context, please provide it here:	Texto	Comentarios libres para aclarar condiciones del ingreso.
What country do you work in?	Texto (sucio)	País de trabajo. Puede presentar diferencias de escritura, abreviaciones o idiomas.
If you're in the U.S., what state do you work in?	Texto	Estado para personas que trabajan en EE.UU.

Nombre de Variable	Tipo de Variable	Descripción
What city do you work in?	Texto (sucio)	Ciudad donde trabaja la persona. Presenta alta variabilidad en escritura.
How many years of professional work experience do you have overall?	Numérico	Años totales de experiencia laboral.
How many years of professional work experience do you have in your field?	Numérico	Años de experiencia en el sector o disciplina actual.
What is your highest level of education completed?	Texto categórico	Nivel educativo más alto alcanzado.
What is your gender?	Texto categórico	Identidad de género del encuestado.
What is your race? (Choose all that apply.)	Texto	Autoidentificación racial o étnica; puede contener múltiples selecciones.

VARIABLES EN BASE DE DATOS PROCESADA

A continuación, se muestran las variables contenidas en el dataset procesado, cada una con su descripción y tipo de variable y nombre de la variable original, hay variables que en el nombre original dicen “Nueva”, esto indica que la variable fué creada dentro del proceso.

Nombre de Variable Original	Nombre de Variable Modelada	Tipo de Variable	Descripción (incluye ajustes realizados)
Timestamp	Timestamp	Fecha / hora	Se conserva sin modificaciones.
How old are you?	Age	Texto categórico	Se renombra para simplificar el análisis manteniendo el rango de edad original.
What industry do you work in?	Industry	Texto	Se estandariza el nombre de la columna; el contenido permanece igual.
Job title	Job_title	Texto	Ajuste de nombre a formato snake_case.

Nombre de Variable Original	Nombre de Variable Modelada	Tipo de Variable	Descripción (incluye ajustes realizados)
If your job title needs additional context, please clarify here:	Job_details	Texto	Se renombra; conserva la descripción libre.
What is your annual salary? (...)	Annual_salary	Texto / numérico	Valor original reportado, previo a limpieza y normalización.
How much additional monetary compensation (...)	Aditional_salary	Texto / numérico	Valor original reportado de compensaciones adicionales.
Please indicate the currency	Currency	Texto categórico	Moneda indicada por el encuestado.
If "Other," please indicate the currency here:	Other_currency	Texto	Se usa para complementar o reemplazar la moneda principal cuando aplica.
If your income needs additional context, please provide it here:	Income_details	Texto	Comentarios sin transformación.
What country do you work in?	Country	Texto	País en formato original, sin limpieza.
If you're in the U.S., what state do you work in?	State	Texto	Sin modificaciones.
What city do you work in?	City	Texto	Ciudad en formato original.
How many years of professional work experience do you have overall?	Years_experience_overall	Numérico	Se renombra; mantiene el valor original.
How many years of professional work experience do you have in your field?	Years_experience_field	Numérico	Se renombra; mantiene el valor original.
What is your highest level of education completed?	Max_education_level	Texto categórico	Renombrada para simplificar el uso analítico.
What is your gender?	Gender	Texto categórico	Sin cambios adicionales.
What is your race? (Choose all that apply.)	Race	Texto	Mantiene selección múltiple original.

Nombre de Variable Original	Nombre de Variable Modelada	Tipo de Variable	Descripción (incluye ajustes realizados)
Nueva	country_std	Texto categórico	País estandarizado corrigiendo mayúsculas, errores ortográficos y variantes.
Nueva	city_std	Texto categórico	Ciudad normalizada para permitir agregaciones.
Nueva	Industry_group	Texto categórico	Clasificación macro derivada mediante reglas de mapeo de industria.
Nueva	Annual_salary_n	Numérico	Conversión del salario anual a número limpio (ej. 80k → 80000).
Nueva	Aditional_salary_n	Numérico	Compensaciones convertidas a valor numérico.
Nueva	Currency_final	Texto categórico	Moneda consolidada priorizando valores válidos sobre “Other”.
Nueva	FX_TO_COP	Numérico	Tasa de cambio aplicada para conversión a pesos colombianos.
Nueva	FX_date	Fecha	Fecha en la que se tomó la tasa de cambio.
Nueva	Annual_salary_cop	Numérico	Salario anual convertido a COP.
Nueva	Aditional_salary_cop	Numérico	Compensaciones convertidas a COP.
Nueva	Total_salary_cop	Numérico	Suma del salario anual y compensaciones en pesos colombianos.
Nueva	Total_salary_mes_cop	Numérico	Promedio mensual del total anual en COP.

Procedimiento para actualizar datos y aplicar el modelado

Con la estructura inicial clara, el siguiente paso es explicar cómo los datos se transforman en información analítica. Esta sección documenta la trazabilidad entre el dataset original y el resultado final.

0) Prerrequisitos

1. Tener acceso al mismo entorno donde corre el notebook (recomendado: **Google Colab**).
2. Tener disponibles en Google Drive (misma carpeta usada en el notebook):
    - SALARY_NAMES.xlsx (descarga/extraído desde Google Sheets público)
    - worldcities.csv (catálogo de ciudades, fuente Kaggle)
    - INDUSTRY.xlsx (tabla de homologación de industrias a macro-grupos)
3. Verificar que las librerías requeridas estén instaladas/importadas:
    - pandas, numpy, re, unidecode, unicodedata, rapidfuzz

---

1) Obtener la versión más reciente de la base (fuente Ask a Manager)

1. Abrir el Google Sheets público de Ask a Manager.
2. Descargarlo como Excel (.xlsx).
3. Guardarlo en Drive en la ruta usada por el notebook, con el mismo nombre:
    - /content/drive/MyDrive/Visualizacion & Storytelling/semana3/SALARY_NAMES.xlsx

Nota operativa: este paso garantiza que el notebook siempre lea “la última versión” sin tocar el código, solo reemplazando el archivo.

---

2) Montar Drive y cargar la base

1. Ejecutar el montaje de Drive:
    - drive.mount('/content/drive')
2. Leer el archivo Excel actualizado:
    - df = pd.read_excel(path)
    - donde path = "/content/drive/MyDrive/Visualizacion & Storytelling/semana3/SALARY_NAMES.xlsx"

Resultado esperado: df contiene las columnas originales (Timestamp, Country, City, Annual_salary, etc.).

---

3) Limpieza y estandarización de Country

Este proceso genera **country_std**:

1. Crear una versión base normalizada (country_clean) con:
    - quitar tildes (unidecode)
    - pasar a minúsculas
    - quitar espacios extra
    - eliminar símbolos no alfabéticos
2. Aplicar un diccionario de reemplazos manuales (dic_paises) para corregir variaciones comunes:
    - Ej: us, usa, united states of america, errores tipográficos, etc.
3. Capitalizar el resultado (title case) para uniformidad:
    - df['country_std'] = df['country_std'].str.title()
4. Identificar valores que no son países (ej: “Europe”, “Global”, textos raros) y marcarlos como:
    - 'Other / Unknown'

Resultado esperado:

- country_std queda con países coherentes + “Other / Unknown” cuando no es clasificable.

---

4) Limpieza y estandarización de City

Este proceso genera **city_std**:

1. Crear base normalizada (city_clean) con:
    - quitar tildes
    - minúsculas
    - limpieza de caracteres extraños
    - eliminación de sufijos cortos raros (regex)
    - normalización de espacios
2. Aplicar correcciones manuales con city_manual (ej: NYC → New York).
3. Cargar el catálogo oficial de ciudades:
    - worldcities.csv desde:
        - /content/drive/MyDrive/Visualizacion & Storytelling/semana3/worldcities.csv
4. Homologar ciudad con fuzzy matching usando rapidfuzz contra cities['city_ascii']:
    - Se aplica una función tipo homologar_ciudad() y se crea:
        - df['city_std'] = df['city_clean'].apply(homologar_ciudad)
5. Exportar casos no reconocidos para revisión humana (control de calidad):

    - Se filtran city_std == 'Other / Unknown'
    - Se exporta a:
        - /content/drive/MyDrive/Visualizacion & Storytelling/semana3/cities5.csv

Resultado esperado:

- city_std con nombres consistentes + “Other / Unknown”
- cities5.csv como insumo de mejora continua.

---

5) Construcción de Industry_group (macro-categorías)

Este proceso genera **Industry_group**:

1. Cargar tabla de homologación:
    - ind = pd.read_excel("/content/drive/MyDrive/Visualizacion & Storytelling/semana3/INDUSTRY.xlsx")
2. Aplicar ajustes manuales a inconsistencias detectadas (industry_red_fixes) si están en el notebook.
3. Construir/usar el mapeo macro (macro_map y reglas complementarias macro_map2) para agrupar industrias.
4. Unir la clasificación al dataset principal con merge:
    - df2 = df.merge(ind[["Industry", "Industry_group"]], on="Industry", how="left")

Resultado esperado:

- df2 contiene una columna Industry_group lista para análisis (incluye “Other” cuando no hay match).

---

6) Limpieza de salarios y compensaciones

Este proceso genera **Annual_salary_n** y **Aditional_salary_n** (numéricos limpios):

1. Aplicar función de limpieza a Annual_salary y Aditional_salary:
    - clean_money_strict(...) para:
        - quitar símbolos/espacios
        - convertir strings a número
        - tratar valores problemáticos
2. Reglas adicionales aplicadas en el notebook:
    - Si Annual_salary_n == 0 ⇒ Aditional_salary_n = 0

    - Si Aditional_salary_n < 0 ⇒ NaN
    - Si Annual_salary_n está entre 1 y 999 ⇒ se interpreta como “miles” y se multiplica por 1000
      (ej: 80 → 80,000)

Resultado esperado:

- Salarios y adicionales convertidos a números consistentes para cálculo.

---

7) Consolidar Currency y asignar tasa de cambio a COP

Este proceso genera **Currency_final**, **FX_TO_COP** y **FX_date**:

1. Normalizar la moneda “Other” con un diccionario (map_other_currency) para convertir texto libre a códigos estándar (USD, EUR, etc.).
2. Crear Currency_final priorizando moneda válida (y usando “Other” cuando aplique).
3. Definir tasas de cambio manuales (fx_manual) y mapear a cada registro:
    - df2["FX_TO_COP"] = df2["Currency_final"].map(fx_manual)
4. Guardar la fecha de la tasa aplicada:
    - df2["FX_date"] = pd.Timestamp.now(tz="America/Bogota").date()

Punto crítico para actualización (TRM):

- En el notebook actual, fx_manual es un diccionario “manual”.
- Para actualizar correctamente cada vez que se corre el ejercicio:
    - reemplazar los valores de fx_manual por la TRM/tasas vigentes del día del ejercicio
    - y asegurarse de que FX_date quede con la fecha real usada.

---

8) Crear variables en COP y totalizar

Este proceso genera los campos finales en pesos colombianos:

1. Convertir salario y adicional a COP:
    - Annual_salary_cop = Annual_salary_n * FX_TO_COP
    - Aditional_salary_cop = Aditional_salary_n * FX_TO_COP
2. Crear total anual y promedio mensual:
    - Total_salary_cop = Annual_salary_cop + Aditional_salary_cop
    - Total_salary_mes_cop = Total_salary_cop / 12

Resultado esperado:

- Campos listos para dashboard: salario, compensaciones y total en COP.

---

9) Exportar el dataset final modelado

1. Guardar el resultado final como Excel:
    - /content/drive/MyDrive/Visualizacion & Storytelling/semana3/SALARY_SALIDA_FINAL4.xlsx
2. El archivo exportado es el que se usa para construir el dashboard.

Checklist rápido (para validar que la corrida salió bien)

- country_std existe y tiene valores tipo “United States”, “Canada”… + “Other / Unknown”
- city_std existe y **no** es igual a City (debe verse más homogéneo)
- Industry_group tiene categorías macro (Technology, Finance / Insurance, etc.)
- Annual_salary_n y Aditional_salary_n son numéricos
- FX_TO_COP no está vacío para monedas principales (USD/EUR/etc.)
- Annual_salary_cop, Total_salary_cop, Total_salary_mes_cop existen y no están en NaN masivo
- Se generó/actualizó SALARY_SALIDA_FINAL{version}.xlsx